

炉石传说立绘生成任务—DCGAN / LSGAN / WGAN-GP / StyleGAN 实验报告

姓名：靳濡搏

学号：231240056

2024 年 12 月 1 日

1 摘要

本实验围绕炉石传说（Hearthstone）卡牌立绘的生成任务，构建并比较了多种生成对抗网络（GAN）架构：DCGAN、LSGAN、WGAN-GP 与简化版 StyleGAN（StyleGAN-lite）。实验主要在 64×64 分辨率下进行，探究不同模型在风格化、小规模数据集上的训练稳定性与生成质量表现。

由于原画数量有限（约 1000 张），图像风格差异较大，实验特别强调数据清洗、归一化与轻度增强。在统一的优化器与训练策略下，模型的稳定性差异非常明显。

实验结果表明，WGAN-GP 在本任务中表现最稳定，生成的图像结构完整性与纹理一致性较优；LSGAN 训练速度快、梯度平滑，但生成结果整体偏模糊；DCGAN 在后期存在模式崩坏现象。由于训练时间与超参数限制，本次实现的 StyleGAN-lite 未能达到预期效果，生成图像质量不稳定，难以体现原论文中 StyleGAN 的优势。

本实验对多类 GAN 进行了统一对照评估，为后续更高分辨率、条件生成或使用官方 StyleGAN2/3 预训练模型开展进一步实验提供基础。

关键词：生成对抗网络；GAN；WGAN-GP；StyleGAN；炉石传说；图像生成

2 实验方法（Method）

本实验旨在构建一个能够自动生成炉石传说原画风格立绘的深度生成模型，比较不同 GAN 架构在训练稳定性、生成质量与细节表达上的差异。

2.1 实验环境

- Windows 11
- Python 3.11, PyTorch 2.1.1+cu121
- GPU: NVIDIA RTX 4060 (16GB)
- CUDA 11.8

2.2 总体流程

实验整体流程如下图所示：



图 1: 炉石立绘生成任务总体流程图

2.3 数据采集与预处理

数据来源 从暴雪 Wiki (<https://blizzard.gamespress.com/zh-CN/Hearthstone/>) 自动爬取 Full Art 等系列的卡面立绘，获取高分辨率原画。

预处理步骤 原始立绘尺寸不统一，且风格混合，因此进行以下处理：

- 图像缩放到 64×64
- 像素归一化到 $[-1, 1]$
- 数据增强：小范围随机裁剪 (95%-97%)、轻微旋转 ($<1^\circ$)、轻微颜色扰动

最终得到 2182 张可用于训练的炉石立绘。(可自行配置倍数, 原画为 1091 张)

2.4 模型架构

本实验实现并比较了四类 GAN：

1. **DCGAN** 经典卷积 GAN，使用 BatchNorm 与 LeakyReLU，结构相对简单。
2. **LSGAN** 将 BCE loss 替换为 MSE，使判别器梯度更平滑。
3. **WGAN-GP** 使用 Wasserstein 距离 + 梯度惩罚，显著提升训练稳定性。

4. **StyleGAN-lite** 本实验实现了一个简化版本的 StyleGAN，包括 Mapping Network、风格调制卷积和逐层噪声注入。然而由于显著的训练开销、较高的超参数敏感性与本地 GPU 算力限制，在 64×64 分辨率下模型未能达到稳定收敛。其生成结果在本实验中不具备明显优势。

示意图如下：




图 2: 四类 GAN 模型结构对比示意图

损失函数

- DCGAN: 使用标准 BCE Loss
- LSGAN: 将 BCE 替换为 MSE，使梯度更稳定
- WGAN-GP: 使用 Wasserstein 距离并加入梯度惩罚项
- StyleGAN-lite: 采用逐层噪声与风格调制结构，但整体训练不稳定

动态学习率机制 本实验为不同模型启用了学习率调度器，以增强训练后期的稳定性并缓解判别器过拟合问题。根据模型类型与训练表现，使用了多种形式的学习率衰减，包括 MultiStepLR 与 Cosine Annealing 调度策略。

在 MultiStep 设置下，生成器与判别器分别在若干预设的 epoch（如 25、60、120、160）触发学习率衰减，衰减比例对两者分别设定，使判别器衰减更快（例如 $\gamma_D = 0.5$ ），以避免判别器过强压制生成器。

此外，对于部分模型使用了余弦退火（Cosine Annealing）策略，使学习率在训练过程中平滑下降，有助于减少后期震荡并提升生成器的稳定性。




图 3: 生成器与判别器学习率随训练 epoch 的衰减示意图 (示例初始 LR = 1)

2.5 训练策略


1. Batch size: 64
2. Epochs: 200 (提高 epochs 能够获取更佳结果, 但会相应的增长训练时间)
3. Optimizer: Adam ($\beta_1 = 0.5, \beta_2 = 0.999$)
4. 对 WGAN-GP: 判别器每轮更新 5 次
5. 受限于本地 GPU 算力 (4060 16GB) 以及 StyleGAN-lite 单 epoch 训练耗时较长, 本实验无法进行足够轮次的收敛训练。
6. 实验中统一固定随机种子 (69), 保证不同模型间生成结果可复现。

最终在统一训练设置下比较不同 GAN 的表现。


3 实验结果 (Results)

3.1 训练曲线


以下为各模型的训练曲线 (各自的超参数均进行了一定程度的超参数调优, 尤其为了抑制 DCGAN 后期的模式崩溃):




(a) LSGAN 训练损失曲线 (未使用学习率衰减)



(b) DCGAN 训练损失曲线 (应用 multistep 学习率衰减)



(c) WGAN-GP 判别器/生成器损失曲线 (未使用学习率衰减)



(d) StyleGAN 训练曲线 (明显看出超参数问题导致的训练崩溃)

图 4: 不同 GAN 变种的训练损失曲线对比

3.2 定性与定量指标

实验中取得成果的三种模型都明显的表现出炉石传说色彩风格, 且有较为鲜明的人物中心感。可认为均取得较为良好的训练效果。

由于本实验的 StyleGAN-lite 未能充分训练且计算 FID/IS 需要额外的 Inception 预处理支持, 本次实验主要以定性分析为主, 不给出数值型 FID/IS 指标。后续工作可基于稳定训练结果补充相关评测。

3.3 可视化生成结果

以下展示部分生成立绘 (选择训练流程中同一种子的生成, 一定程度上展示训练变化):




图 5: LSGAN 生成结果 (从左到右依次为 epoch50,100,150,200)




图 6: DCGAN 生成结果 (从左到右依次为 epoch60,120,150,180)




图 7: WGAN-GP 生成结果 (从左到右依次为 50,100,150,200, 可观测到 Late-stage drift)

StyleGAN 未训练出稳定模型, 不提供生成结果.

3.4 消融实验

3.4.1 LR-Schedule

学习率衰减对于 DCGAN 的崩溃有明显的抑制作用 (可对比4b):




图 8: 无学习率调整策略下 DCGAN 训练结果, 可见训练不稳定

在无学习率调度的情况下, 训练至约第 40 epoch 后判别器损失降至 0.4 以下, 生成器损失持续高于 3, 表明生成器梯度消失, 训练进入不稳定状态。

3.4.2 Batch

选取 Batch=32 与 64 在无调度策略下作对比实验 (取点拟合):




图 9: 不同 Batch Size 下 DCGAN 的判别器与生成器损失曲线对比 (无学习率衰减)

从曲线可以看出, 两种配置的 loss 变化趋势基本一致: 训练初期 D Loss 快速下降, G Loss 先降后升; 在约第 40 epoch 后, 判别器损失降至很低水平 (batch_size=64 最低至 0.399, batch_size=32 最低至 0.449), 而生成器损失持续上升至 4 5 以上, 表明生成器梯

度消失，训练进入不稳定状态。相比之下，较小的 `batch_size=32` 使判别器收敛速度稍慢、最低点略高，这是由于小批量梯度估计方差更大，减缓了判别器过早主导训练的过程。但总体来看，仅减小 `batch_size` 并不能根本避免训练失衡，仍需借助学习率衰减或多步调度等策略平衡两者学习速率。因此，在 DCGAN 训练中引入 MultiStepLR 等策略是必要的

4 评价分析 (Evaluation)

本节对比分析不同 GAN 的表现。

DCGAN 初期收敛较快，但在后期经历明显的模式崩坏 (即使应用了动态学习率进行抑制)，图像结构开始瓦解。模型对学习率较为敏感。

LSGAN 损失曲线平滑，训练稳定性优于 DCGAN，但生成图像偏模糊，细节表现不佳。

WGAN-GP 整体最稳定。梯度惩罚有效抑制了判别器过强的问题，生成的结构和纹理明显优于 DCGAN/LSGAN。训练速度适中，是本实验中表现最好的模型。

StyleGAN-lite 由于实现简化加上训练时间不足 (单 epoch 约 8 分钟)，模型未能有效学习数据分布。生成图像缺乏结构性，与真实炉石立绘差距明显。本实验结果不能代表官方 StyleGAN 的真实性能。如果训练能持续超过 200 个 epoch (或使用更完整的 StyleGAN2/3 架构)，模型质量预计会有显著提升。

5 讨论与总结 (Discussion)

本实验系统比较了四类 GAN 在炉石传说风格立绘生成上的能力。整体实验表明：

- WGAN-GP 是本次任务中效果最稳定、生成质量最佳的模型；
- LSGAN 和 DCGAN 可作为轻量级基线，但生成纹理与结构有限；
- 简化版 StyleGAN 在本实验条件下无法有效收敛，不具备参考意义；
- 动态学习率有助于延缓 DCGAN/LSGAN 的模式崩坏；
- 数据质量与分辨率限制是影响炉石原画生成效果的关键因素。

未来可尝试：

1. 使用官方 StyleGAN2 或 StyleGAN3 的训练管线与预训练模型；

2. 采用 Progressive Growing 逐步提升分辨率；
3. 引入条件生成（文本、职业标签、卡牌类型）；
4. 在 128×128 或更高分辨率上重训模型；
5. 进一步探索判别器正则化与稳定性技术（R1、path length regularization）。

致谢

感谢炉石 Wiki 提供高质量素材。本项目参考了相关开源实现与论文结构，同时部分文字排版与结构建议由语言模型工具辅助生成，但所有模型实现、训练与实验分析均由本人独立完成。

参考文献

- [1] Goodfellow, Ian, et al. "Generative adversarial networks." *Advances in Neural Information Processing Systems*, 2014.
- [2] Radford, Alec, Luke Metz, and Soumith Chintala. "Unsupervised representation learning with deep convolutional generative adversarial networks." *ICLR*, 2016.
- [3] Mao, Xudong, et al. "Least squares generative adversarial networks." *ICCV*, 2017.
- [4] Gulrajani, Ishaan, et al. "Improved training of Wasserstein GANs." *NIPS*, 2017.
- [5] Karras, Tero, et al. "A style-based generator architecture for generative adversarial networks." *CVPR*, 2019.
- [6] Karras, Tero, et al. "Analyzing and improving the image quality of StyleGAN." *CVPR*, 2020.
- [7] Karras, Tero, et al. "Alias-free generative adversarial networks." *NeurIPS*, 2021.

A 附录 Appendix

A.1 数据集样例




图 10: 左: 原始炉石立绘; 右: 扩容预处理后图像; 分辨率为 64x64 因此较为模糊

A.2 错误案例与失败分析



图 11: 崩溃的图像 (右侧纯色为训练失败的 styleGAN)

A.3 更多生成结果




图 12: 左:LSGAN; 中:DCGAN; 右:WGAN-GP